

## تشخیص گفتار — خلاصه معیارها

ارزیابی مدل‌های محلی تبدیل گفتار فارسی به متن (FLEURS fa\_ir)، به همراه معیارهای بالینی برای ارزیابی گزارش‌های رادیولوژی دیکته شده. دلیل استفاده از هر معیار.

■ آبی = افزوده شده برای ارزیابی بالینی (رادیولوژی). مشکی = مجموعه اولیه معیارهای STT.

### دقت

| معیار                | چرا استفاده می‌کنیم                                                                      |
|----------------------|------------------------------------------------------------------------------------------|
| WER                  | درصد کلمات غلط — معیار اصلی و استاندارد ASR.                                             |
| CER                  | درصد نویسه‌های غلط — برای پسوندها و واژه‌بست‌های چسبیده فارسی منصفانه‌تر است.            |
| chrF                 | همپوشانی n-گرم نویسه‌ای — به تغییرات صرفی که WER کاملاً غلط می‌شمارد امتیاز نسبی می‌دهد. |
| BERTScore (ParsBERT) | تطابق معنایی در سطح توکن — به مترادف‌های درست که WER جریمه می‌کند امتیاز می‌دهد.         |
| شباهت معنایی         | تطابق معنای کل جمله با embedding — آیا پیام حفظ شده است.                                 |

### پایایی (حیاتی برای کاربرد پزشکی)

| معیار                    | چرا استفاده می‌کنیم                                                       |
|--------------------------|---------------------------------------------------------------------------|
| SER                      | درصد کلیپ‌هایی که هر خطایی دارند — رونوشت چند وقت یکبار کامل است.         |
| WER P50 / P90 / P95      | کلیپ‌های معمول در برابر بدترین حالت؛ میانگین، پرت‌های بد را پنهان می‌کند. |
| % کامل / % فاجعه‌بار     | سهم کلیپ‌های بی نقص در برابر به شدت غلط.                                  |
| نرخ جایگزینی / درج / حذف | نوع خطا؛ درج = کلمات توهمی (بالاترین ریسک پزشکی).                         |
| نرخ خروجی خالی           | مدل چند وقت یکبار هیچ خروجی نمی‌دهد.                                      |

### حالت‌های خطای خاص فارسی

| معیار         | چرا استفاده می‌کنیم                                                           |
|---------------|-------------------------------------------------------------------------------|
| نسبت توهم     | طول خروجی به مرجع؛ بیشتر از ۱ یعنی ساختن کلمه.                                |
| آلودگی خط     | درصد نویسه‌های غیرفارسی — نشأت لاتین/انگلیسی را نشان می‌دهد.                  |
| امتیاز تکرار  | n-گرم‌های تکراری — توهم حلقه‌ای Whisper روی سکوت را می‌گیرد.                  |
| F1 نقطه‌گذاری | مقایسه منصفانه مدل‌های نقطه‌گذار (Whisper) با مدل‌های متن خام (Wav2Vec2/MMS). |

برای دیکته رادیولوژی معتبر نیست. معیار «آلودگی خط» فرض می‌کند نویسه لاتین یعنی نشأت. در دیکته رادیولوژی، گوینده عمداً فارسی را با اصطلاحات انگلیسی مخلوط می‌کند (hydronephrosis, UVJ, mm)؛ بنابراین یک رونوشت کاملاً درست، «به شدت آلوده» امتیاز می‌گیرد. این معیار را مخصوص FLEURS بدانید، یا آن

را با معیاری جایگزین کنید که بسنجد اصطلاحات انگلیسی درست نوشته شده‌اند یا نه — نه اینکه اصلاً وجود دارند یا نه.

## دقت بالینی (گزارش‌های رادیولوژی دیکته‌شده)

روی متن گزارش و در برابر مرجع تأییدشده توسط رادیولوژیست سنجیده می‌شود. ریسک بالینی در همین معیارهاست — یک گزارش می‌تواند WER خوبی داشته باشد و همچنان نایمن باشد.

| معیار                         | چرا استفاده می‌کنیم                                                                                                                                                         |
|-------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| نرخ خطای نفی                  | وارونه‌شدن وجود/عدم وجود — «سنگ وجود ندارد» که «سنگ وجود دارد» رونویسی شود. تشخیص را کاملاً عوض می‌کند.                                                                     |
| نرخ خطای سمت                  | جابه‌جایی راست/چپ (Right/Left) — یافته را به سمت اشتباه بدن منتقل می‌کند.                                                                                                   |
| نرخ خطای عدد                  | مقدار اندازه‌گیری غلط — پریسک‌ترین دسته خطا؛ سنگ ۶ میلی‌متری که ۱ سانتی‌متر خوانده شود، تصمیم درمانی را تغییر می‌دهد.                                                       |
| نرخ خطای واحد                 | mm در برابر cm در برابر میلی‌متر و سانتی‌متر. کمیت فیزیکی مقایسه شود، نه رشته واحد — تا ۱۰ میلی‌متر و ۱ سانتی‌متر برابر شمرده شوند.                                         |
| دقت اصطلاح پزشکی (Precision)  | از اصطلاحات بالینی تولیدشده، چند تا واقعاً در مرجع پشتیبانی می‌شوند — اصطلاح‌سازی ساختگی را می‌گیرد.                                                                        |
| بازیابی اصطلاح پزشکی (Recall) | از اصطلاحاتی که باید می‌بودند، چند تا باقی مانده‌اند — یافته‌های حذف‌شده را می‌گیرد.                                                                                        |
| F1 اصطلاح پزشکی               | یک عدد ترکیبی برای کیفیت کلی اصطلاحات.                                                                                                                                      |
| نرخ حذف بحرانی                | محتوای مهم مرجع که در خروجی نیست. «بحرانی» باید صریح تعریف شود (اندازه‌گیری، یافته نفی‌دار، نشانگر سمت، یا اصطلاح علامت‌گذاری‌شده) وگرنه به «هر چیز جافتاده» تقلیل می‌یابد. |
| نرخ افزوده بی‌پشتوانه         | محتوای خروجی که هیچ پشتوانه‌ای در مرجع ندارد — همان حالت جعل (مثلاً مدلی که سابقه بیماری دیکته‌نشده می‌سازد).                                                               |
| پرچم requires_medical_review  | برای هر گزارش، با بروز هر خطای بحرانی فعال می‌شود. در گردش‌کار پس‌ویرایش، این پرچم بعد از تأیید نهایی روشن می‌شود؛ پس یک محرک بازبینی ثانویه است، نه یک سد ایمنی.           |

## حلقه پس‌ویرایش (پایش زنده)

وقتی مرجع، نسخه تصحیح‌شده خروجی خودمان توسط رادیولوژیست باشد، معنای اعداد فرق می‌کند: میزان تلاش ویرایش را می‌سنجند، نه درستی را.

| معیار                        | چرا استفاده می‌کنیم                                                                                                                                    |
|------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|
| بار ویرایش (WER) (پس‌ویرایش) | رادیولوژیست چقدر مجبور شده تغییر بدهد. یک سیگنال بار کاری تولید — آن را «دقت» نخوانید، چون مرجع از متن خود مدل مشتق شده است.                           |
| %پذیرش بدون تغییر            | سهم گزارش‌هایی که بدون هیچ ویرایشی تأیید شده‌اند. باید در کنار نشانه‌های تعامل دیده شود: گزارشی که فقط مهر تأیید خورده، از گزارش درست قابل تفکیک نیست. |

| معيار            | چرا استفاده می‌کنیم                                                                                                              |
|------------------|----------------------------------------------------------------------------------------------------------------------------------|
| نرخ بازگشت تصحيح | چه سهمی از خروجی‌ها اصلاً تصحيح‌شده برمی‌گردند. بازگشت کم یا سوگیرانه یعنی نمونه ارزیابی به سمت گزارش‌های آسان‌تر منحرف شده است. |