

نقشه راه آماده‌سازی برای تولید

فاین‌تیون یک مدل رونویسی رادیولوژی برای گفتار ترکیبی فارسی و انگلیسی؛ از پایپ‌لاین فعلی تا مدلی قابل استقرار روی دستگاه کاربر

دامنه: فقط پایپ‌لاین رونویسی/فاین‌تیون (داده ← مدل پایه ← آموزش ← ارزیابی ← بسته‌بندی برای استقرار ← پایلوت).
سخت‌سازی نرم‌افزاری خود کنترلر FastAPI خارج از دامنه‌ی این سند است.

بازه‌های زمانی، تخمین‌های تقریبی برای برنامه‌ریزی هستند، نه تعهد قطعی — این تخمین‌ها بر پایه‌ی یک تیم کوچک و متمرکز است و شدیداً به نحوه‌ی تحویل دیتاست سراسری شهر بستگی دارد (خام در برابر ازپیش جفت‌شده/تأییدشده).

خلاصه‌ی مدیریتی

کنترلر Spin BuAli از پیش سه پایپ‌لاین فعال دارد (separate با STT و reconcile، multimodal با LLM صوتی، و Gemini 2.5) که روی دیکته‌های واقعی اجرا می‌شوند. مقایسه‌ی خروجی‌های موجود از چند مدل (hybrid reconcile) از طریق مرحله‌ی GPT-5 و Aya-Expanse، به همراه Whisper-large-v3، Gemma-4-12B، Pro/Flash، روی فایل‌های صوتی یکسان، الگویی روشن نشان داد: فقط قوی‌ترین مدل ابری (Gemini 2.5 Pro) گزارش‌هایی پیوسته قابل اعتماد روی این محتوا تولید می‌کند. مدل‌های محلی/سبک به شکل‌های قابل شناسایی شکست می‌خورند — Whisper-large-v3 اصلاً نمی‌تواند کدسویچینگ فارسی/انگلیسی را مدیریت کند، و هم یافته‌های بالینی جعلی می‌سازد که در صوت وجود ندارند و گاهی وارد چرخه‌ی تکرار متن Gemma-4-12B می‌شود. در میان مدل‌ها، بیشترین اختلاف در اندازه‌گیری‌های عددی دقیق (اندازه‌ی سنگ، فاصله تا یک لندمارک، ابعاد کیست) دیده می‌شود — بزرگ‌ترین ریسک ایمنی بالینی در این سیستم.

پیشینه‌ی منتشرشده نشان می‌دهد این کار شدنی است: یک مدل Whisper Tiny برای گفتار بالینی ترکیبی بنگالی-انگلیسی فاین‌تیون شده و روی مجموعه‌ی آزمون خودش به دقتی تقریباً کامل رسیده، و محصولات دیکته‌ی رادیولوژی روی دستگاه (مثل RadMyk) از قبل به‌طور کامل روی سیستم شخصی رادیولوژیست و بدون اجرا می‌شوند. مسیر پیشنهادی همین دستورالعمل شناخته‌شده است: فاین‌تیون یک نسخه‌ی GPU از پیش‌آموزش‌دیده و فارسی‌پذیر از Whisper روی داده‌ی صوت و گزارش‌های تأییدشده‌ی خود این پروژه، به‌جای ادامه‌ی تکیه بر پرامپت‌نویسی روی مدل‌های آماده.

کاندیدهای مدل پایه به چک‌پوینت‌های خانواده‌ی Whisper که از قبل از فارسی پشتیبانی می‌کنند محدود شدند بررسی و رد شدند — هیچ‌کدام فارسی را پشتیبانی (Parakeet-TDT، Moonshine، NVIDIA Canary، و vhdn/whisper-large-fa-v1) نمی‌کنند. نقطه‌ی شروع پیشنهادی vhdn/whisper-large-fa-v1 است، یک فاین‌تیون فارسی از Whisper را دارد، بنابراین فاین‌تیون CPU که از قبل هم آواشناسی فارسی و هم سرعت مناسب برای large-v3-turbo — این پروژه فقط لازم است کدسویچینگ و تطبیق با حوزه‌ی رادیولوژی را روی آن اضافه کند، نه اینکه پشتیبانی زبان را از صفر بسازد.

نقشه راه در یک نگاه

زمان تخمینی	تمرکز	فاز
تکمیل‌شده	خط پایه و تعریف مسئله	0
4-10 هفته	جمع‌آوری و آماده‌سازی داده	1
1-2 هفته	انتخاب مدل پایه و محک‌زنی خط پایه	2
6-10 هفته	فاین‌تیون	3
1-2 هفته (+2-4 در صورت فعال‌شدن)	اصلاح/تطبیق: ابتدا پرامپت، فاین‌تیون فقط در صورت نیاز	4
2-3 هفته	ارزیابی و اعتبارسنجی ایمنی بالینی	5

زمان تخمینی	تمرکز	فاز
2-4 هفته	بسته‌بندی برای استقرار	6
4-8 هفته	اجرای آزمایشی (پایلوت)	7
مستمر	حلقه‌ی پایش و بازآموزی	8

بهترین حالت برای رسیدن به اولین پایلوت تولیدی (فازهای 1 تا 7، با هم‌پوشانی فازهای #3/#4): تقریباً 5 تا 7 ماه. فاز 1 (داده) اصلی‌ترین منبع عدم قطعیت است — اگر دیتاست سراسری شهر از پیش جفت‌شده و توسط رادیولوژیست تأیید شده برسد، این زمان کوتاه‌تر می‌شود؛ اگر گزارش‌ها نیاز به تأیید مورد به مورد در برابر صوت داشته باشند، این زمان به‌طور قابل‌توجهی فراتر از بازه‌ی بالا می‌رود.

فاز 0 — خط پایه و تعریف مسئله

وضعیت: تکمیل شده

این فاز پیش‌تر، در جریان کار ارزیابی اولیه‌ی این پروژه، انجام شده است.

آنچه مشخص شد

- بررسی کنترلر موجود (پایپ‌لاین‌های separate / multimodal / hybrid) و سیستم‌پرامپت‌های آن.
- مقایسه‌ی خروجی‌های واقعی از بیش از ۶ پیکربندی مدل/پایپ‌لاین روی همان ۴ دیکته (Gemini 2.5 reconcile) از طریق Flash/Pro، Gemma-4-12B، Whisper-large-v3+Aya-Expanse، GPT-5).
- تأیید شد که Gemini 2.5 Pro در حال حاضر قوی‌ترین عملکرد را دارد؛ Whisper-large-v3 محلی روی کدسوییچینگ فارسی/انگلیسی شکست می‌خورد؛ Gemma-4-12B سابقه‌ی بالینی جعل می‌کند و می‌تواند وارد چرخه‌ی تکرار متن شود.
- مشخص شد اندازه‌گیری‌های عددی (اندازه‌ی سنگ، فاصله‌ها، ابعاد کیست) بیشترین اختلاف را میان مدل‌ها دارند — پریسک‌ترین حالت خطا برای یک گزارش رادیولوژی.
- پیشینه‌ی منتشرشده برای ASR بالینی کدسوییچ‌شده و فاین‌تیون‌شده روی دستگاه بررسی شد — تأیید می‌کند رویکرد کلی روی سخت‌افزار واقعی شدنی است.
- به‌عنوان مدل پایه رد شدند — هیچ‌کدام در حال حاضر از Parakeet-TDT و Moonshine، NVIDIA Canary، و فارسی پشتیبانی نمی‌کنند.

خطر — اعداد منتشرشده، اعداد شما نیستند

پیشینه‌ی ذکرشده در بالا نشان می‌دهد این رویکرد به‌طور کلی شدنی است، نه اینکه مدل خود این پروژه روی صوت خودش به چه دقتی می‌رسد. تا زمانی که فاز 5 اعداد واقعی این پروژه را تولید کند، معیارهای بیرونی را فقط به‌عنوان نشانه‌ای از قابل‌قبول بودن در نظر بگیرید.

فاز 1 — جمع‌آوری و آماده‌سازی داده

این فاز، گلوگاه واقعی کل نقشه راه است. انتخاب مدل و روش آموزش خیلی کم‌اهمیت‌تر از این هستند که آیا گزارش‌های ground-truth واقعا درست‌اند و به‌درستی با صوت خودشان جفت شده‌اند یا نه.

فعالیت‌ها

- جمع‌آوری دیتاست صوتی سراسری شهر همراه با گزارش‌های نهایی متناظرش.
- حذف اطلاعات هویتی بیمار پیش از اینکه هر صوت یا متنی به هیچ ابزار یا فضای ذخیره‌سازی بیرونی برسد.
- اطمینان از اینکه متن ground-truth همان «گزارش نهایی تأییدشده توسط رادیولوژیست» است، نه یک پیش‌نویس خام قبلی STT/LLM — آموزش روی پیش‌نویس‌های تأییدنشده، مدل را وادار می‌کند خطاهای امروز را بازتولید کند.
- یکسان‌سازی صوت (فرمت، نرخ نمونه‌برداری، تعداد کانال) در سرتاسر دیتاست.
- لایه‌بندی دیتاست بر اساس نوع بررسی (شکم/لگن و غیره)، شرایط ضبط (فاصله‌ی میکروفون، نویز پس‌زمینه)، و گوینده، تا تقسیم‌های train/validation/test نماینده‌ی واقعی باشند.
- تقسیم بر اساس بیمار/جلسه‌ی ضبط (نه بر اساس هر گزارش به‌تنهایی) تا از نشت همان گوینده/جلسه بین train و test جلوگیری شود.
- جداکردن یک زیرمجموعه‌ی آزمون اختصاصی و پر از اندازه‌گیری‌های عددی — چون یافته‌های عددی بالاترین ریسک بالینی را دارند، این بخش به پوشش ارزیابی هدفمند نیاز دارد، نه فقط یک نمونه‌ی تصادفی.
- تأیید حقوق استفاده از داده/رضایت برای آموزش روی این دیتاست، پیش از شروع کار.

خطر — ورودی بی‌کیفیت، خروجی بی‌کیفیت

اگر گزارش‌های «ground truth» صرفاً رونویسی‌های تاریخی باشند نه متنی که به‌طور مستقل تأیید شده درست است، فاین‌تیون همان الگوهای شکست موجود در پایپ‌لاین فعلی (مثل یافته‌های کلیشه‌ای جعلی، اندازه‌گیری‌های غلط) را تقویت می‌کند — فقط با اطمینان بیشتر.

فاز 2 – انتخاب مدل پایه و محک زنی خط پایه

1-2 هفته

پیش از دست زدن به آموزش، باید مشخص شود هر کاندیدای فارسی پذیر، بدون هیچ تغییری، روی دیتاست جدید در چه وضعیتی است — این همان عددی است که هر فاز بعدی در برابر آن سنجیده می‌شود.

کاندیدها (رتبه‌بندی‌شده)

نقش	پارامترها	مبنا	مدل
کاندیدای اصلی	809M	فاین تیون فارسی از Whisper large-v3-turbo	vhdm/whisper-large-fa-v1
کنترل / جایگزین	809M	چک‌پوینت اصلی OpenAI (بدون تغییر)	openai/whisper-large-v3-turbo
مرجع سقف دقت	1.55B	فاین تیون فارسی از نسخه‌ی کامل large-v3	MohammadGholizadeh/whisper-large-v3-persian-common-voice-17
جایگزین سبک‌وزن	39M	فاین تیون فارسی از Whisper Tiny	aictsharif/whisper-tiny-fa

فعالیت‌ها

- اجرای هر چهار کاندیدا، بدون تغییر، روی یک نمونه‌ی کنارگذاشته‌شده (held-out) از دیتاست جدید.
- تعیین Word Error Rate (WER) پایه برای هر کاندیدا.
- تعریف یک معیار وزن‌دهی‌شده بر اساس حوزه — یک «Medical Concept WER» — که خطاها روی اصطلاحات بالینی و اندازه‌گیری‌های عددی را بسیار سنگین‌تر از کلمات پرکننده امتیاز می‌دهد، چون اندازه‌ی غلط یک سنگ خیلی مهم‌تر از افتادن یک «اه» است.
- مقایسه‌ی هر چهار کاندیدا با بهترین نقطه‌ی مرجع فعلی (Gemini 2.5 Pro، multimodal) تا اندازه‌ی شکافی که فاین تیون باید ببندد مشخص شود.

فاز 3 — فاین تیون

10-6 هفته

تطبیق مدل(های) پایه‌ی انتخاب‌شده برای کدسویچینگ و واژگان رادیولوژی، با استفاده از دیتاست آماده‌شده در فاز 1.

روش پیشنهادی: LoRA مرحله‌ای تا فاین تیون کامل

مرحله A — فاین تیون بهینه از نظر پارامتر (LoRA / QLoRA)

آداپترها روی لایه‌های attention/projection هم در encoder و هم در decoder آموزش می‌بینند، نه فقط میان‌بر رایج زمانی است که مسئله صرفاً واژگانی باشد، اما بخشی از مسئله‌ی decoder-تطبیق فقط decoder. این پروژه آکوستیک است (فاصله‌ی میکروفون، نویز پس‌زمینه، گفتار سریع/نامفهوم) که در encoder جای دارد، پس encoder هم باید تطبیق پیدا کند. این مرحله ارزان و سریع است و وظیفه‌اش اعتبارسنجی کل مسیر داده-تا-آموزش-تا-ارزیابی، سر تا ته، پیش از صرف محاسبات بزرگ‌تر است.

مرحله B — فاین تیون کامل

تمام وزن‌ها بدون قفل، پس از آنکه مرحله‌ی A مسیر را تأیید کرد و حجم واقعی دیتاست مشخص شد. فاین تیون کامل معمولاً ریسک فراموشی فاجعه‌بار (catastrophic forgetting) و overfitting روی دیتاست‌های کوچک را دارد، اما دیتاستی در مقیاس یک شهر برای توجیه آن به‌اندازه‌ی کافی بزرگ است و به سقف دقتی به‌مراتب بالاتر از آداپترها به‌تنهایی می‌رسد. از نرخ یادگیری پایین همراه با warmup استفاده کنید و بخش کوچکی از گفتار فارسی عمومی (غیررادیولوژی) را در دسته‌های آموزشی بگنجانید تا مدل حین تخصصی‌شدن، توانایی عمومی ASR فارسی را از دست ندهد.

فعالیت‌ها

- مرحله A: ابتدا فاین تیون LoRA/QLoRA روی یک زیرمجموعه‌ی اعتبارسنجی‌شده و کنارگذاشته‌شده، تا مشکلات داده یا پایپ‌لاین پیش از اجرای پرهزینه، ارزان شناسایی شوند.
- مرحله B: فاین تیون کامل روی کل دیتاست آماده‌شده، پس از تأیید مرحله A.
- آموزش و مقایسه‌ی حداقل دو کاندیدای برتر از فاز 2 (vhdn/whisper-large-fa-v1 و کنترل turbo اصلی) در هر مرحله، تا فاین تیون حوزه‌ای در برابر یک خط پایه‌ی منصفانه سنجیده شود.
- تکرار در هر مرحله: آموزش، اعتبارسنجی روی تقسیم کنارگذاشته‌شده، مقایسه‌ی چک‌پوینت‌ها، تکرار.

خطر — محاسبات آموزش، محاسبات استقرار نیست

فاین تیون به محاسبات GPU نیاز دارد (ابری یا داخل‌سازمانی)، هرچند مدل نهایی مستقرشده باید فقط روی CPU سیستم رادیولوژیست اجرا شود. این‌ها دو نیاز زیرساختی جداگانه‌اند — اندازه‌گیری آن‌ها در بخش «زیرساخت و داده‌ی موردنیاز» در انتهای این سند آمده است؛ برنامه‌ی آموزش را بر اساس سخت‌افزار هدف استقرار طراحی نکنید.

فاز 4 — اصلاح/تطبیق: ابتدا پرامپت، فاین تیون فقط

1-2 هفته (+4 هفته بیشتر)

فقط در صورت فعال شدن)

در صورت نیاز

مرحله‌ی reconcile موجود در کنترلر (pipelines.py) از پیش از یک LLM می‌خواهد خروجی STT را با استفاده از یک سیستم پرامپت و یک قالب JSON ثابت پاکسازی کند. این رویکرد باید ابتدا امتحان شود، نه اینکه از پیش ناکافی فرض شود — فاین تیون این مرحله هزینه‌ی واقعی اضافه‌ای دارد و فقط باید زمانی صرف شود که پرامپت به‌تنهایی کافی نباشد.

عامل تعیین‌کننده، اندازه‌ی مدل است. در مقایسه‌ی فاز 0، همین رویکرد پرامپت+قالب روی یک مدل ابری بزرگ در همان وظیفه بد شکست (Gemma-4-12B) خوب کار کرد، اما روی یک مدل محلی کوچک (Gemini 2.5 Pro) خورد — سابقه‌ی بیماری‌ای جعل کرد که در صوت وجود نداشت و وارد چرخه‌ی تکرار متن شد. از آنجا که استقرار تولیدی به یک مدل کوچک نیاز دارد که روی سیستم رادیولوژیست بدون GPU اجرا شود، همین الگوی شکست است که اینجا اهمیت دارد، و هنوز مشخص نیست که آیا پرامپت به‌تنهایی، پس از فاین تیون سمت STT، برای جلوگیری از آن کافی است یا نه.

فعالیت‌ها

- استفاده از همان LLM کوچک و قابل‌استقرار محلی که برای تولید انتخاب شده، با اعمال پرامپت/قالب فاین تیون‌شده، به‌علاوه‌ی دستور STT از خروجی واقعی مدل few-shot موجود، همراه با چند مثال reconcile صریح برای علامت‌گذاری مقادیر عددی نامطمئن به‌جای حدس‌زدن.
- محک‌زنی این نسخه‌ی فقط-پرامپتی در فاز 5 در برابر خروجی واقعی STT فاین تیون‌شده.
- فقط اگر در آن نقطه هنوز یافته‌ها را جعل می‌کند، وارد چرخه‌ی تکرار می‌شود، یا مقادیر عددی را غلط می‌گیرد: ساخت یک مجموعه‌ی جفتی (خروجی خام STT ← گزارش تأییدشده) از خطاهای واقعی و فاین تیون LLM اصلاح‌گر روی آن.

خطر — فرض نکنید پرامپت بین اندازه‌های مختلف مدل منتقل می‌شود

پرامپت/قابلی که روی یک مدل ابری بزرگ خوب کار می‌کند، دلیلی بر کارکردنش روی مدل محلی کوچکی که تولید واقعا به آن نیاز دارد نیست — روی همان مدل هدف استقرار تست کنید، نه روی هر مدلی که در مقایسه‌های اولیه در دسترس بود.

فاز 5 – ارزیابی و اعتبارسنجی ایمنی بالینی

نقطه‌ی رسمی go/no-go پیش از شروع هر کار مربوط به استقرار.

فعالیت‌ها

- محک‌زنی STT فاین‌تیون‌شده به‌همراه مرحله‌ی اصلاح تنظیم‌شده، در برابر خط‌های پایه‌ی فاز 2 و بهترین پایپ‌لاین فعلی کنترلر (Gemini 2.5 Pro، multimodal)، روی مجموعه‌ی آزمون کنارگذاشته‌شده.
- اجرای ممیزی اختصاصی اندازه‌گیری‌های عددی از زیرمجموعه‌ی آزمون فاز 1 – این پرسیک‌ترین حوزه است و به معیار pass/fail صریح خودش نیاز دارد، نه فقط یک عدد WER کلی.
- بازیابی کور توسط رادیولوژیست: نمونه‌ای از خروجی‌های مدل، بدون اطلاع از اینکه کدام مدل تولیدشان کرده، در برابر ground truth تأییدشده بررسی می‌شود.
- استرس‌تست مستقیم حالت‌های مرزی: فاصله‌ی دور/نزدیک میکروفون، گفتار هم‌پوشان یا بسیار سریع، اصطلاحات کمیاب یا غیرمعمول.

خطر – پیش از رسیدن به معیار، آن را تعریف کنید

پیش از شروع این فاز، روی یک آستانه‌ی حداقلی پذیرش (مثلاً نرخ تطابق دقیق روی یافته‌های عددی) توافق کنید. بدون یک معیار ازپیش‌تعیین‌شده، توجیه «به‌اندازه‌ی کافی خوب است» زیر فشار استقرار آسان می‌شود.

فاز 6 — بسته‌بندی برای استقرار

تبدیل مدل اعتبارسنجی‌شده به چیزی که واقعا روی سیستم رادیولوژیست اجرا می‌شود.

فعالیت‌ها

- کوانتیزه کردن مدل نهایی (int8 از طریق CTranslate2 / whisper.cpp) برای inference روی CPU.
- محک‌زنی real-time factor روی سخت‌افزار نماینده‌ی ایستگاه کاری رادیولوژیست — نه یک سیستم توسعه‌دهنده — تا تأیید شود تخمین‌های سرعت قبلی CPU در عمل هم برقرارند.
- بسته‌بندی مدل به صورت یک سرویس HTTP محلی، مطابق با رابطی که کنترلر از پیش در STT_URL انتظار دارد (config.py، پیش‌فرض localhost:8000) — این نقطه‌ی یکپارچه‌سازی طبیعی است چون کنترلر از پیش را به عنوان یک سرویس محلی قابل‌جایگزینی در نظر گرفته STT
- تأیید اینکه سرویس بسته‌بندی‌شده از طریق هر سه پایپ‌لاین موجود (separate/multimodal/hybrid) بدون نیاز به تغییر بیشتر در pipelines.py کار می‌کند.

فاز 7 – اجرای آزمایشی (پایلوت)

اعتبارسنجی در دنیای واقعی با یک گروه کوچک، پیش از هر گسترش بزرگ‌تر.

فعالیت‌ها

- اجرای یک پایلوت با چند رادیولوژیست که گزارش‌های واقعی (جدید) را دیکته می‌کنند، همزمان و موازی با فرایند فعلی‌شان.
- ثبت اصلاحاتی که رادیولوژیست‌ها روی خروجی مدل انجام می‌دهند، به‌عنوان داده‌ی آموزشی جدید و به‌طور طبیعی تأییدشده.
- پیگیری همان معیارهای فاز 5 (WER، Medical Concept WER، دقت اندازه‌گیری عددی) در شرایط واقعی، نه فقط روی مجموعه‌ی آزمون کنارگذاشته‌شده.

خطر – پایلوت برای معنادار بودن به زمان واقعی نیاز دارد

چهار تا هشت هفته یک عدد ثابت نیست – این مدت‌زمانی است که معمولاً برای جمع‌آوری دیکته‌های واقعی کافی و بازخورد رادیولوژیست لازم است تا سیگنال قابل‌اعتماد باشد. کوتاه‌کردن این مدت، ریسک تصمیم‌گیری بر اساس نویز را بالا می‌برد.

فاز 8 — حلقه‌ی پایش و بازآموزی

مستمر

آماده‌بودن برای تولید، برای مدلی مثل این، یک خط پایان یک‌باره نیست — دقت باید پایش شود و مدل باید مسیری برای بهبود مستمر داشته باشد.

فعالیت‌ها

- برقراری یک فرایند مستمر (با رضایت) برای جمع‌آوری گزارش‌های تازه‌اصلاح‌شده به‌عنوان داده‌ی آموزشی آینده.
- تعیین یک ریتم دوره‌ای بازآموزی با استفاده از اصلاحات جمع‌شده از استفاده‌ی واقعی.
- نسخه‌بندی مدل‌ها و نگه‌داشتن مسیر بازگشت به آخرین چک‌پوینت known-good.
- ادامه‌ی پیگیری اختصاصی معیار دقت اندازه‌گیری عددی در تولید، نه فقط WER کلی — این معیاری است که بیشترین پیوند را با ریسک بالینی دارد.

زیرساخت و داده‌ی موردنیاز

آنچه پیش از شروع فاز 1 باید خریداری، اجاره، یا مذاکره شود. این بخش، درخواست منابع برای این نقشه راه است، نه یک بودجه‌ی عمومی IT — هرچه در ادامه آمده، دقیقاً محدود به نیاز این نه فاز است.

محاسبات (آموزش)

آموزش به محاسبات GPU نیاز دارد؛ مدل مستقرشده ندارد. دو مرحله‌ی متفاوت آموزش به دو رده‌ی متفاوت GPU نیاز دارند، و هیچ‌کدام لازم نیست به‌طور کامل خریداری شوند — هر دو با اجاره‌ی کوتاه‌مدت ابری (AWS، GCP، یا مشابه) برای هفته‌هایی که هر مرحله واقعاً اجرا می‌شود، جور درمی‌آیند، Azure، RunPod، Lambda Labs.

نحوه‌ی تأمین	حداقل GPU	هدف	مرحله
اجاره‌ی ابری، چند روز تا چند هفته	1 عدد GPU با 16GB VRAM (مثلاً RTX 4090/3090، یا نمونه‌ی ابری هم‌رده‌ی A10G)	فاین‌تیون LoRA/QLoRA؛ اعتبارسنجی ارزان پایپ‌لاین	مرحله A (فاز 3)
اجاره‌ی ابری، چند هفته؛ خرید را فقط اگر بازآموزی فاز 8 مکرر شود در نظر بگیرید	1 عدد GPU با 40GB VRAM (مثلاً A100 40GB/80GB، یا نمونه‌ی هم‌رده‌ی H100)	فاین‌تیون کامل روی حجم داده در مقیاس شهر	مرحله B (فاز 3)
چیزی برای هر جایگاه خریداری نمی‌شود	هیچ — فقط CPU، حدود 3GB RAM 4GB برای مدل کوانتیزه‌شده	اجرای مدل نهایی روی سیستم رادیولوژیست	استقرار (فاز 6 به بعد)

به این عدم‌تقارن توجه کنید: محاسبات پرهزینه به‌طور کامل در بخش آموزش (فازهای 2 تا 4، و بازآموزی دوره‌ای فاز 8) متمرکز است. چیزی در استقرار به سخت‌افزار GPU برای هر رادیولوژیست یا هزینه‌ی ابری مستمر نیاز ندارد.

داده

- ورودی اصلی: خود دیتاست صوت رادیولوژی سراسری شهر به‌همراه گزارش‌های نهایی متناظرش. این نیازمند یک توافق رسمی دسترسی/اشتراک‌گذاری داده با هر نهادی است که آن را در اختیار دارد — یک دروازه‌ی پیش‌نیاز پیش از آنکه فاز 1 بتواند به‌طور قانونی آغاز شود، و مهم‌ترین مورد سطح مدیرعامل برای مذاکره در این فهرست.
- فضای ذخیره‌سازی: نیاز به اندازه‌گیری پس از مشخص‌شدن حجم واقعی دیتاست دارد، اما برای این حجم صوت، ده‌ها تا صدها گیگابایت را در نظر بگیرید، روی فضای ذخیره‌سازی سریع (SSD) برای توان عملیاتی ورودی/خروجی آموزش.
- امنیت: این داده‌ی بیمار است — ذخیره‌سازی، صرف‌نظر از حجم نهایی، از همان لحظه‌ی جمع‌آوری به رمزنگاری در حالت سکون و کنترل دسترسی نیاز دارد.
- رضایت/مجوز نظارتی برای استفاده از صوت و گزارش‌های بیمار در آموزش مدل — پیش از شروع فاز 1 مشخص شود، نه در میانه‌ی راه.

حداقل صوت + برجسب موردنیاز

بر پایه‌ی نتایج منتشرشده‌ی فاین تیون Whisper (مطالعات تطبیق حوزه‌ای/کم‌منبع، بهبود قابل‌توجه WER را حتی از 1 تا 8 ساعت صوت آموزشی گزارش می‌دهند که با افزایش داده بهتر هم می‌شود)، در اینجا مقیاس بزرگ‌تری در نظر گرفته شده چون گفتار کدسویچ‌شده، پرنویز، و سریع، دشوارتر از موارد عمده‌تک‌زبان‌ای است که آن مطالعات پوشش می‌دهند.

نتیجه	تعداد ضبط*	صوت مورد نیاز	رده
اعتبارسنجی پایپ‌لاین (فاز 3، مرحله A) — ثابت می‌کند رویکرد کار می‌کند، مشکلات داده/تنظیمات را ارزان شناسایی می‌کند	~150-300	5-10 ساعت	کف حداقلی
کیفیت قابل قبول برای تولید، آماده برای مواجهه با ارزیابی فاز 5	~600-1,500	30-50+ ساعت	حداقل عملی
جایی که فاین تیون کامل (مرحله B) هزینه‌اش را نسبت به تنها LoRA به‌وضوح جبران می‌کند	~2,000+	100+ ساعت	هدف بلندپروازانه

* تخمین تقریبی با فرض ضبط‌های 1 تا 4 دقیقه‌ای، هم‌راستا با فایل‌های نمونه‌ی بررسی‌شده برای این نقشه راه — پس از رسیدن دیتاست واقعی، میانگین طول واقعی آن را تأیید کنید.

- تنوع به‌اندازه‌ی حجم اهمیت دارد: پوشش میان رادیولوژیست‌های مختلف، انواع بررسی، و شرایط ضبط (میکروفون نزدیک/دور، نویز پس‌زمینه) بسیار بهتر از همان تعداد ساعت از یک برش محدود، تعمیم پیدا می‌کند.
- هر ساعت شمرده‌شده در بالا فرض می‌کند برچسبی تأییدشده توسط رادیولوژیست دارد، طبق فاز 1 — یک رونویسی تأییدشده در این حداقل محاسبه نمی‌شود.
- تنظیم LLM اصلاح‌گر در فاز 4 (در صورت فعال‌شدن) به شکل دیگری سنجیده می‌شود و به‌مراتب کمتر نیاز دارد: چند صد تا حدود 1 تا 2 هزار جفت متنی تأییدشده‌ی (خروجی STT ← گزارش اصلاح‌شده)، چون در حال تطبیق دادن یک LLM کوچک از پیش توانمند با یک وظیفه‌ی محدود است، نه یادگیری آکوستیک از صفر.
- پیامد عملی: کف تقریبی 5 تا 10 ساعت برای شروع مرحله A از فاز 3 کافی است، به‌محض آنکه همین مقدار از دیتاست نهایی در دسترس باشد — فاز 1 لازم نیست پیش از آغاز کار آموزش، کاملاً تکمیل شود.

افراد

- مهندس(ان) ML برای اجرای پایپ‌لاین داده، آموزش، ارزیابی، و کار بسته‌بندی (فازهای 1 تا 6).
- زمان رادیولوژیست — یک ردیف منابع واقعی، نه فقط یک مورد مهندسی. برای تأیید گزارش‌های فاز 1)، بازبینی کور خروجی مدل (فاز 5)، و مشارکت در پایلوت (فاز 7) لازم است. این اغلب ground-truth گلوگاه واقعی پروژه‌ای مثل این است، نه محاسبات.
- یک تماس حوزه‌ی حاکمیت داده/حقوقی برای مذاکره و نهایی‌کردن توافق دسترسی به داده‌ی بالا.

ابزارها (اختیاری، کم‌هزینه)

- ابزار پیگیری آزمایش (مثل Weights & Biases یا MLflow) برای مقایسه‌ی چک‌پوینت‌ها در تکرارهای آموزشی فاز 3.

- یک تنظیمات ساده‌ی registry/نسخه‌بندی مدل برای حلقه‌ی بازآموزی در فاز 8.